



Projet de Développement Logiciel

Document des spécifications techniques

Sujet 3: MatrixSynthesizeWikipedia

M1 MIAGE Université de Rennes 1 BUSSON Vivien
LELIÈVRE Lucas
PELLETIER Vincent
LE HUEROU Clément
LA RIVIERE Olivier

Sommaire

I - Presentation du projet	3
II - Wikidata	5
1 - Présentation	5
2 - Récupération des données de Wikidata	6
3 - Structure du .json d'une page Wikidata	7
4 - API existante de Wikidata	10
III - Wikipédia	11
1 - Présentation	11
2 - L'API de MediaWiki	11
3 - Fonctionnement de l'API	11
3.1 - L'URL principale de l'API	11
3.2 - Les paramètres de l'API	12
4 - Les Infobox de wikipédia	13
4.1 - Introduction aux Infobox	13
4.2 - Utilisation des Infobox	13
IV - Pistes de développement	14
V - Maquettes	16
VI - Réflexions	18
VII - Annexes	20

I - Présentation du projet

Le but de ce projet est de générer des matrices de comparaison au format ".csv" à partir des données de Wikipédia ou Wikidata (au choix). Aucunes données ne devra être saisies manuellement, l'utilisateur devra simplement renseigner les champs des valeurs à récolter. Ces matrices seront ensuite importées dans "OpenCompare" qui se chargera de la mise en forme de celles-ci.

Après exécution de votre programme Java, vous devriez donc obtenir un fichier ".csv" tel que présenté ci-dessous :

	A	В	C	D
1	pays	France	Espagne	Italie
2	nb_Habitants	67595000	46439864	61302519
3	superficie (km²)	672369	505911	301336
4	langue_principale	français	espagnol	italien
5	type_etat	republique	monarchie	republique
6	- Colonia de la	alia da constituido .		

Figure 1.1 - Résultats dans le fichier csv.

Dans cet exemple, la comparaison a lieu sur les caractéristiques des pays, à savoir France, Espagne et Italie. Ici, on collecte les informations sur le nombre d'habitants, la superficie, etc.

Il devra également être possible de comparer des images, exemple : des drapeaux lors d'une recherche sur des pays.

Lorsque que l'utilisateur saisira les champs d'information à rechercher, il faudra mettre en place une stratégie afin de contourner le cas des mots ayant plusieurs sens (exemple : Python qui est un langage de programmation et également un animal).

Pour résumer les différentes actions que l'utilisateur devra réaliser voici un diagramme de cas d'utilisation de l'application.

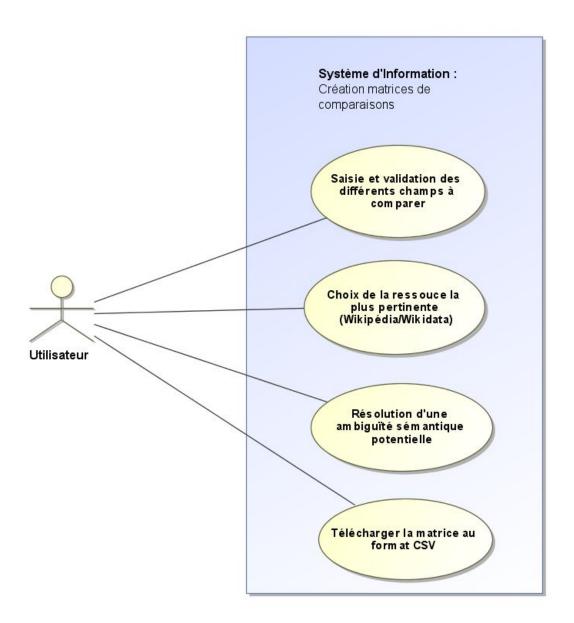


Figure 1.2 - Diagramme de cas d'utilisation.

II - Wikidata

https://www.wikidata.org

1 - Présentation

Wikidata est une base de données participative basée sur des technologies web. Elle a été lancée en 2012 par Wikimedia. Elle permet de centraliser des données présentes dans différents projets tels que Wikipédia.

Contrairement aux encyclopédies classiques, Wikidata prend la forme de données brutes, à savoir des couples clés/valeurs sans rédaction autour des informations. Par exemple dans le cas d'un pays, on trouvera les clés "Langue", "Taille", "Population" associées aux valeurs "Français", "5000 Km²", "30 000 000".

Étant un projet Wikimedia, les modifications effectuées dans les données de Wikidata se répercutent dans tous les projets du groupe (Wikipédia en tête), et vice-versa.

Wikidata fournit de nombreuses informations sur notre "univers" et des liens vers d'autres bases de données. Les données publiées sont diffusées au public, elles sont utilisables et modifiables par quiconque. De plus, Wikidata est maintenu par la communauté d'éditeurs.

Wikidata est utilisé dans Wikipédia. En effet, ces données peuvent être introduites :

- dans les infobox ;
- dans les tableaux, histogrammes et autres graphiques de présentation de données;
- pour afficher les liens vers des bases de données reconnues telles que les notices d'autorité.

En revanche, les données Wikidata ne peuvent pas être utilisées :

- dans les parties rédigées des articles (résumé introductif, paragraphes de texte, etc.);
- dans des palettes de navigation ;
- dans les bandeaux de portails ;
- pour la présentation des bibliographies ;

2 - Récupération des données de Wikidata

Tout d'abord, il y a plusieurs façon d'accéder aux données de Wikidata. Par exemple, il est possible d'obtenir les données pour un élément ou bien d'obtenir l'intégralité des données grâce aux fichiers de dumps, ou encore, des exportations périodiques des données de la base dans un ou des fichiers téléchargeables.

Chaque élément présenté par Wikidata possède une clé unique, un id permettant de retrouver facilement ces données. Cette clé prend la forme suivante : la lettre "Q" suivie d'un numéro (identifiant unique).

Pour illustrer notre explication, avec la page Wikidata de la France, on obtient la clé "Q142". Celle-ci est récupérable à plusieurs endroits : sur la page elle-même ou à côté du titre (voir ci-dessous), et donc accessible via son url et son code source.



Figure 2.2.1 - Clé de l'élément d'une page Wikidata.

Ensuite, une fois la clé obtenue, il est possible de récupérer toutes les données de la page par l'intermédiaire de son json. Celui-ci est accessible par une url, suivant le modèle ci-après : http://www.wikidata.org/wiki/Special:EntityData/Q142.json (exemple des données JSON pour la France).

Cependant, le plus complexe dans l'utilisation de Wikidata est la récupération de la clé de la page associée à la recherche saisie par l'utilisateur. De plus, il faudra mettre en place un système permettant de choisir le sens le plus pertinent d'un mot lorsque celui-ci possède des homonymes (exemple du mot "python"). Lors de cette première partie du module de PDL, notre groupe a développé une approche en java de cet aspect technique.

Le code de cette fonctionnalité est disponible sur notre "repository" Github à l'adresse suivante : https://github.com/LucasLEL/PDL_part1 .

En utilisant le code que nous avons développé, il est possible de récupérer, par le biais d'une console, les identifiants des pages associées à une recherche spécifique préalablement saisie. En sélectionnant un résultat dans la liste des choix, il est ainsi possible d'afficher les informations associées.

Il est important de noter que ce code n'est qu'une ébauche. Celui-ci a pour but de vous présenter le fonctionnement de la récupération des données avec Wikidata. Il est réalisé de la façon qui nous semblait la plus judicieuse, vous pouvez bien évidemment le modifier pour l'adapter à vos besoins.

Voici le détails des éléments affichés en console lors de l'exécution de notre programme :

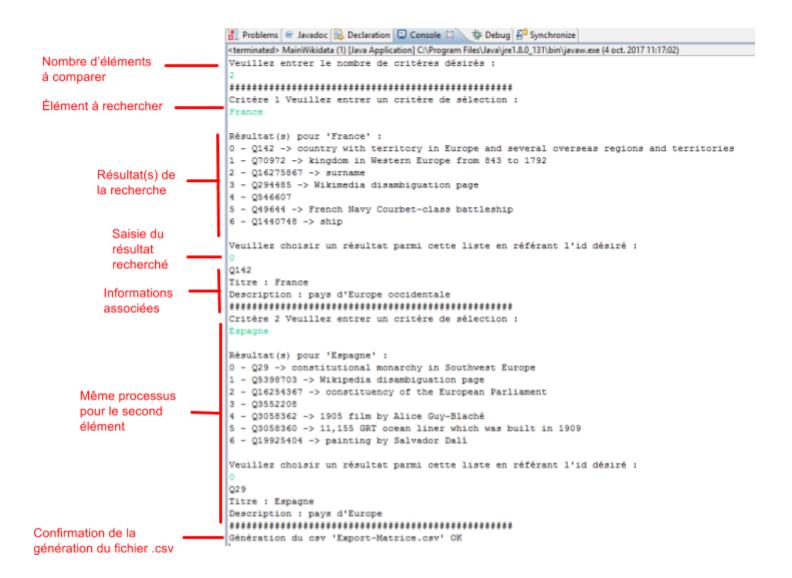


Figure 2.2.2 - Résultat de l'exécution de notre programme.

3 - Structure du .json d'une page Wikidata

Comme expliqué précédemment, toutes les pages Wikidata possèdent une page ".json" où sont stockées toutes les informations.

Ces pages possèdent toutes la même structure. Nous allons la décrire ci-dessous.

```
"entities":⊡{
      "Q142": 🗆 {
          "pageid":277,
          "ns":0,
          "title": "Q142",
          "lastrevid":573616707,
          "modified": "2017-10-07T12:02:51Z",
          "type":"item",
          "id":"Q142",
          "labels": ⊞ {...},
          "descriptions": ⊞ {...},
          "aliases": ⊞{_},
          "claims": ⊞ {...},
          "sitelinks": ⊞{...}
  3
}
```

Figure 2.3.1 - Contenu type du .json d'une page Wikidata.

La hiérarchie Json débute par une clé "entities" qui sera présente sur chaque page sous ce nom. Ensuite, vient l'identifiant de la page, à savoir le "Q+numéro". Cette information permet d'indiquer que les données devront être associées à la page ayant ce numéro. Les informations spécifiques à la page apparaissent ensuite, et sont réparties dans des catégories différentes. Les premières, à savoir "pageid", "ns", "title", "lastrevid", "modified", type", "id" sont des informations portant davantage sur la structure de la page (titre, dernière modification, etc.).

Les données qui suivent sont plus intéressantes. Dans un premier temps, nous allons nous intéresser à la partie "labels", "descriptions" et "aliases", trois catégories d'informations qui sont associées.

Dans "labels", on retrouve le titre "manuscrit" de la page, c'est-à-dire que l'identifiant (Q+numéro) que l'on a utilisé jusqu'à présent est traduit par un mot ou une phrase pour la première fois. C'est à ce moment que l'on associe un numéro d'identifiant à une recherche spécifique (exemple : Q142 = FRANCE). On obtient ainsi le titre "réel" de la page Wikidata. Dans "descriptions", une phrase décrivant l'élément est stockée. Cette phrase sera affichée comme introduction sur la page Wikidata.

Enfin, dans "aliases", tous les alias associés à cette recherche sont énumérés. Ils seront affichés sous le titre et la phrase d'introduction sur la page Wikidata.



Figure 2.3.2 - Organisation de la page Wikidata par le biais du json.

Pour ces trois champs, les informations sont disponibles dans un grand nombre de langues. La liste de celles-ci s'obtient en déroulant les clés du Json. Voici ci-dessous l'utilisation de cette liste.

```
"labels": □ {
    "en": ⊞ {__},
    "fr": ⊞ {__},
    "ru": ⊞ {__},
    "de": ⊞ {__},
    "es": ⊞ {__},
```

Figure 2.3.3 - Organisation par langue dans le Json

Ceci permet de traduire l'ensemble des pages Wikidata selon la langue sélectionnée. Par exemple, si l'utilisateur sélectionne le langage "Espagnol", alors l'affichage de Wikidata n'ira chercher que les "labels", "descriptions" et "aliases" ayant comme sous clé "es" et ne prendra pas en compte les autres informations.

Ensuite, vient la partie "Claims" du ".json". Il s'agit de toutes les informations "réelles" de la page. Si par exemple nous nous trouvons sur la page d'un pays, c'est à cet endroit que les champs "population", "superficie", etc. seront stockés avec leur valeur associée. De plus, les données sont affichées de manière "brutes", il faudra donc, dans notre code, utiliser un autre nom ou identifiant. Il sera nécessaire de mettre en oeuvre un mécanisme pour traduire et récupérer l'information souhaitée. Cet aspect est évoqué dans la partie "Réflexions" de ce document.

Pour finir, la partie "sitelinks" permet de stocker les URLs des pages Wikipédia de l'élément recherché sous différentes langues. Ces liens sont affichés dans le bas de la page Wikidata.

4 - API existante de Wikidata

Wikidata propose une API "officielle" qui est disponible sur Github via le lien suivant : https://github.com/Wikidata/Wikidata-Toolkit.

Cette API est en fait une bibliothèque Java permettant d'accéder aux APIs Wikidata.

Il s'agit d'une API conséquente et complexe, dont la plupart des fonctionnalités ne sont pas en adéquation avec nos problématiques. Nous avons tout de même testé quelques fonctionnalités notamment au travers de la classe "FetchOnlineDataExample.java" qui permettait de ressortir des informations grâce à l'id d'une page (exemple "Q142").

Afin de simplifier le code que nous vous avons fourni, nous avons créé notre propre classe "API" tout en s'inspirant de celle évoquée précédemment.

Nous vous conseillons tout de même d'explorer cette API si vous souhaitez ajouter des fonctionnalités à l'application. Celle-ci peut vous aider lors de la seconde phase du projet.

III - Wikipédia

https://www.wikipedia.org/

1 - Présentation

Wikipédia est une célèbre encyclopédie libre, numérique, et multilingue, créé par Jimmy Wales et Larry Sanger en 2001. Elle contient plus de 46 millions d'articles, complétés et modifiés par des millions d'auteurs bénévoles à travers le monde, c'est-à-dire que chacun peut la modifier et y ajouter du contenu à tout moment. Elle est devenue la plus importante base de connaissance partagée de toute l'histoire de l'humanité. Ces millions d'articles et de données sont également disponibles via l'API de MediaWiki.

2 - L'API de MediaWiki

MediaWiki est le moteur de wiki développé et utilisé par Wikipédia. MediaWiki possède une API sous forme de service web, qui permet un accès facilité aux fonctionnalités et aux données de Wikipédia, via une URL. Cette API fournit un accès direct et de haut niveau aux données contenues dans les bases de données MediaWiki. Ainsi, des programmes clients comme le programme JAVA qui doit être développé pour ce projet, peuvent se connecter à un wiki et y obtenir ces données de manière simple et autonome.

3 - Fonctionnement de l'API

3.1 - L'URL principale de l'API

Voici l'URL principale de l'API : https://en.wikipedia.org/w/api.php. La version française de cette API s'obtient en changeant le « en » en « fr » : https://fr.wikipedia.org/w/api.php. Cette URL est le point d'entrée de l'API, c'est-à-dire que chaque appel à l'API commencera forcément par cette URL de base.

3.2 - Les paramètres de l'API

Plusieurs paramètres vont être ajoutés à l'URL de base pour préciser l'information que l'on souhaite obtenir. En voici les principaux :

- le paramètre « format » qui constitue le format de récupération des données. Exemple « format=json » demande à l'API de récupérer les données au format JSON.
- Le paramètre « action » qui précise l'action que l'on souhaite effectuer. La fonctionnalité principale de ce projet étant la récupération de données via des API, l'action pour ce projet est l'action : « action=query ».
- Le paramètre « titles » qui précise le nom de la page recherché. Exemple si l'on souhaite obtenir des informations sur la ville de Paris, le paramètre « titles » est : « titles=Paris ».
- Le paramètre « prop » qui précise les propriétés de la page recherchée. Par exemple, pour obtenir le résumé de la page Paris, il faut ajouter le paramètre « prop » suivant : « prop=extracts ».

Par exemple, nous pouvons utiliser cette URL pour obtenir le résumé de la page Wikipédia Paris, au format JSON :

https://fr.wikipedia.org/w/api.php?action=query&prop=extracts&titles=paris&exintro=1&format=json

Pour plus de précisions et d'informations sur l'API MediaWiki, la documentation officielle se trouve aux adresses suivantes :

https://www.mediawiki.org/wiki/API:Main_page

https://www.mediawiki.org/wiki/API:Query

4 - Les Infobox de wikipédia

4.1 - Introduction aux Infobox

Sur l'exemple précédent, nous vous avons présenté comment récupérer le résumé de la page Wikipédia Paris, au format JSON. Nous pouvons remarquer que les pages wikipédia contiennent des informations textuelles massives, et difficilement structurée.

Par la suite, il serait plus judicieux de s'intéresser exclusivement aux Infobox des pages Wikipédia, qui ne contiennent que des informations essentielles et de façon structurée. Il est donc plus facile de traiter ces informations au sein de l'application.



4.2 - Utilisation des Infobox

Pour récupérer l'infobox d'une page wikipédia, il est possible d'appeler l'API présentée précédemment et de filtrer les informations issues des infobox.

Voici un exemple avec l'infobox de la page de l'ISTIC au format JSON :

https://fr.wikipedia.org/w/api.php?action=query&prop=revisions&rvprop=content&format = json&titles=Unit%C3%A9 de formation et de recherche en informatique et %C3%A9l ectronique de l%27universit%C3%A9 de Rennes 1&rvsection=0

À noter que cette piste de récupération des Infobox d'une page wikipédia contient également le résumé de celle-ci. Il est donc nécessaire de sélectionner que les informations contenu dans les balises {{Infobox ... }}.

Pour visualiser l'information dans un format propre à l'API de Wikipedia, pour la rendre plus visualisable, modifier le paramètre format de l'URL : "&format=xmlfm".

IV - Pistes de développement

Afin de mener à bien ce projet, quelques diagrammes de conception ont été réalisés. Ils prennent en compte les axes principaux du projet, sans rentrer dans les détails de chaque fonctionnalité.

Pour commencer, le diagramme de séquence global de l'application :

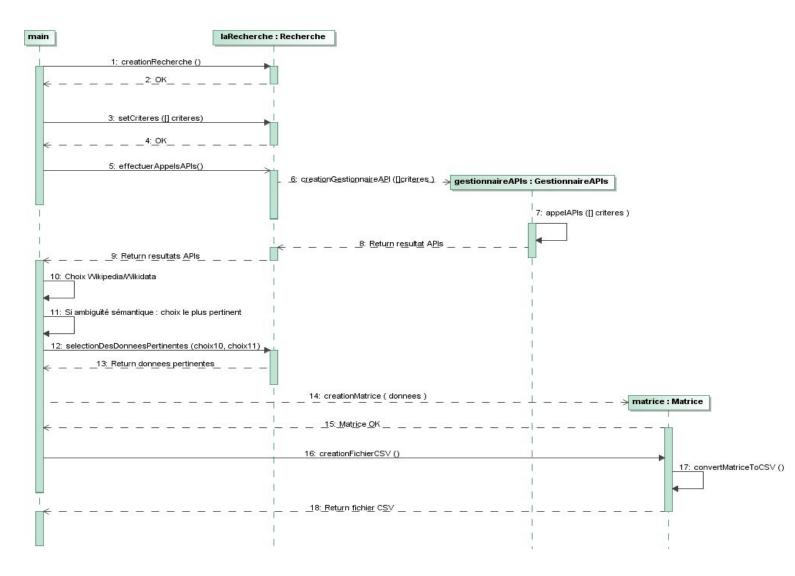


Figure 4.1 - Diagramme de séquence.

Nous avons également réalisé un prototype de diagramme de classes qui pourra être implémenté dans la partie 2 de ce projet.

Il est important de noter que l'ébauche du code que nous avons développé pour cette première partie de projet n'utilise qu'une partie de ce diagramme de classe.

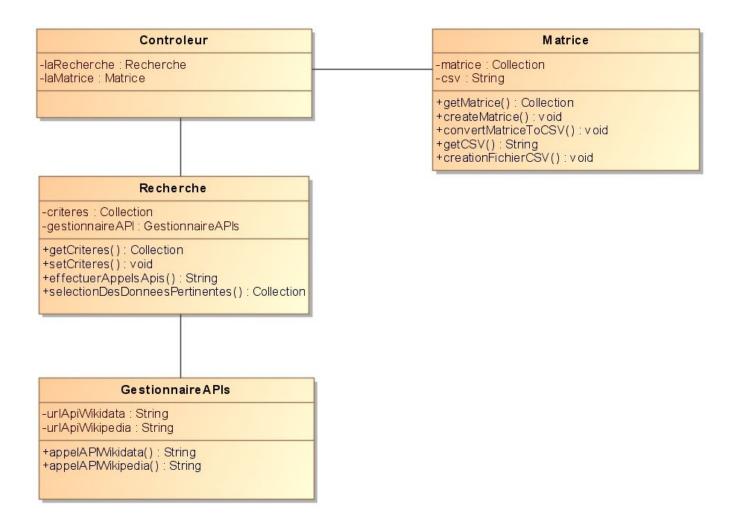
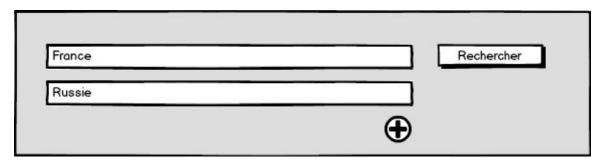


Figure 4.2 - Diagramme de classes.

V - Maquettes

Voici une première maquette qui pourra être réalisée dans la deuxième partie du projet. Il est important de noter que cette interface peut d'ores et déjà utiliser le code Java développé durant la première partie du projet.

Tout d'abord, la première vue est composée de plusieurs barres de recherches, qui peuvent par ailleurs être ajoutées en cliquant sur le bouton "+". L'utilisateur peut ainsi entrer ses différents critères de recherches (un critère par barre de recherche). Une fois saisi(s), l'utilisateur peut valider sa recherche.



Dans un second temps, une deuxième vue s'affiche, contenant le résultat de la recherche, via les APIs.

☑ - Q142 -> Pays avec u		
∐ - Q70972 -> Royaume	de France de 843 à 1792	
☐ - Q1440748 -> Bateau		
☐ - Q19230985 -> Poème	ope de l'est et du nord de l'A	
□ - Q19230985 -> Poémo □ - Q690108 -> Bateau	•	
Q010108 -> Bateau		

Plusieurs résultats s'offrent à l'utilisateur, pour chaque critères de recherche. Il peut ainsi cocher le résultat plus pertinent par critère, au vue de sa recherche. L'intérêt de cette sélection est de désambiguïser certains résultats, exemple pour le critère "Python", qui a plusieurs significations.

Après la sélection des résultats, l'utilisateur peut enfin générer la matrice de comparaison des différents critères au format CSV (exemple concret d'un fichier CSV généré avec le code de la première partie ci-dessous).

	A	В
1	Titre	Description
2	Allemagne	pays d'Europe
3	Espagne	pays d'Europe
4	France	pays d'Europe occidentale
5	Pologne	pays d'Europe centrale
6	Russie	pays d'Europe et d'Asie

Figure 5.1 - Affichage du csv.

Voici le résultat du fichier CSV importé dans "OpenCompare" :

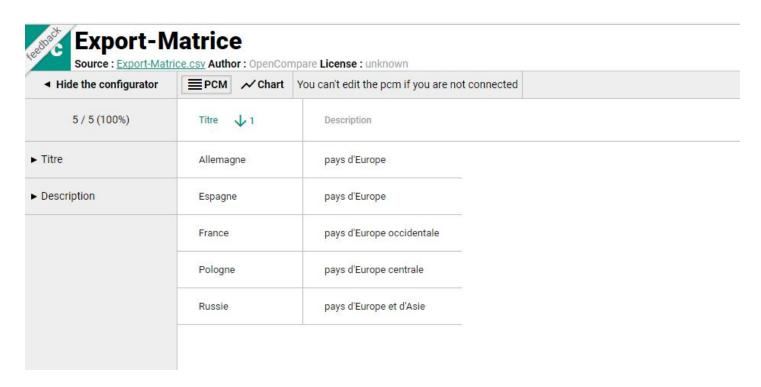


Figure 5.2 - Affichage dans OpenCompare.

VI - Réflexions

Voici quelques idées que nous avons eu concernant les futures améliorations et évolutions sur ce projet :

- Actuellement, la recherche d'un élément propose plusieurs résultats en anglais. Il serait envisageable de trouver un mécanisme de traduction dans la langue de l'utilisateur.
- Les données de Wikidata sont disponibles dans un grand nombre de langues. Les résultats pourraient être dans la langue choisie par l'utilisateur au lancement de l'application.
- Les données de Wikidata sont trop diverses selon les résultats des recherches. En effet, il est impossible de comparer un pays avec un bateau. Actuellement le système va générer une matrice qui est potentiellement erronée. Il sera donc nécessaire de gérer ce problème, en effectuant, par exemple, une comparaison des descriptions des éléments sélectionnés.
- Concernant Wikipédia, les données sont massives et non structurées. Il serait plus judicieux de travailler exclusivement sur les Infobox des pages Wikipédia présentées précédemment dans ce rapport.
- Chaque information d'un élément Wikidata, par exemple un champ "population" pour l'élément France, est masqué/associé par un id de type P+nombre (exemple : P1082 pour la population). Il sera donc nécessaire de traduire ces éléments pour les inclure dans la matrice. A partir d'une page d'un élément il est possible de cliquer sur une propriété (ex : population) pour afficher la page Wikidata de celle-ci. Nous pouvons également obtenir le "P+nombre", à ce moment, dans le titre de la page.

Lien pour une propriété : https://www.wikidata.org/wiki/Property:P1082

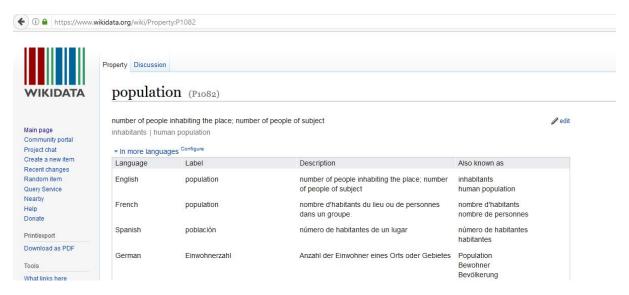


Figure 6.1 - Correspondance Id "P1082" avec la propriété "Population".

- Pour plus de compréhension, voici un site utile vous permettant d'afficher des fichiers JSON de façon plus lisible : http://json.parser.online.fr/ (exemple en ANNEXE).
- Lors de certaines recherches, des résultats apparaissent avec comme descriptions "Wikimedia disambiguation page" (page d'homonymie d'un projet Wikimédia), c'est à dire que différents sujets et articles partagent un même nom. Par exemple pour la recherche "Samsung", plusieurs résultats apparaissent comme étant des pages de "désambiguïsation". Il serait donc utile de gérer ces cas de recherche.

```
Critère 1 Veuillez entrer un critèrere de sélection :

Samsung

Résultat(s) pour 'Samsung' :

0 - Q3470976 -> Wikimedia disambiguation page

1 - Q20716 -> South Korean multinational conglomerate

2 - Q21156650 -> Wikimedia disambiguation page

3 - Q2217741 -> Wikimedia disambiguation page

4 - Q21164410 -> Wikimedia disambiguation page

5 - Q27791642 -> Wikimedia disambiguation page

6 - Q25114506 -> Wikimedia disambiguation page
```

Figure 6.2 - Exemple "Wikimedia disambiguation page", issue du code que nous avons implémenté pour cette première partie de projet

VII - Annexes

```
⊡{
   "entities": ⊡{
      "0142": ⊡{
        "pageid":277,
        "ns":0,
         "title": "Q142",
         "lastrevid":572269159,
         "modified": "2017-10-04T18:18:32Z",
         "type":"item",
         "id":"0142",
         "labels": ⊞ {...},
         "descriptions": ⊞{...},
         "aliases": ⊞{__},
         "claims": □{
            "P610": ⊞ [2],
            "P1546": ⊞[3],
            "P1036": ⊞[1],
            "P1151": ⊞[1],
            "P1082": ⊞[60],
           "P31": ⊞[6],
           "P38": ⊕[5],
            "P36": ⊕[1].
            "P30": ⊕[5].
            "P47": ⊞[18],
            "P41": □[
               □{
                  "mainsnak":⊡{
                     "snaktype": "value",
                     "property": "P41",
                     "datavalue":⊡{
                        "value": "Flag of France.svg",
                        "type":"string"
                     "datatype": "commonsMedia"
                  },
                  "type": "statement",
                  "qualifiers": □{
                     "P580": □[
                         □{
                            "snaktype": "value",
                            "property": "P580",
                            "hash": "5044e5f0836caee424504fea4c27cce057ad7563",
                           "datavalue": □{
                               "value": □{
                                  "time":"+1794-05-20T00:00:00Z",
                                  "timezone":0,
                                  "before":0,
                                  "after":0,
                                  "precision":11,
                                  "calendarmodel": "http://www.wikidata.org/entity/
```

Annexe 1 - Arborescence du fichier JSON avec le site "json.parser.online".